



Машинное обучение в науках о Земле

Михаил Криницкий

К.Т.Н.

Зав. лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Института океанологии РАН им. П.П. Ширшова



Сокращение размерности

Михаил Криницкий

К.Т.Н.

Зав. лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Института океанологии РАН им. П.П. Ширшова

ПЛАН ЛЕКЦИИ

- Сокращение размерности
 - PCA (Principal Components Analysis, Метод главных компонент)
 - t-SNE (t-distributed Stochastic Neighbor Embedding)*
 - UMAP (Uniform Manifold Approximation and Projection)**

*Hinton, Geoffrey E., and Sam Roweis. "Stochastic neighbor embedding." Advances in neural information processing systems 15 (2002).

**McInnes L., Healy J., Melville J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction // arXiv:1802.03426 [cs, stat]. 2020.

ОЧЕНЬ КРАТКОЕ ВВЕДЕНИЕ В МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ

типы задач:

- «Обучение с учителем»
 - восстановление регрессии
 - классификация
- «Обучение без учителя»
 - Снижение размерности
 - Кластеризация

Снижение размерности

что у меня есть?

признаковое описание объектов

что я хочу?

снизить размерность признакового описания объектов

Снижение размерности

что у меня есть?

признаковое описание объектов

что я хочу? **Так а чо, какие проблемы-то?**

снизить размерность признакового описания объектов

Снижение размерности

что у меня есть?

- признаковое описание объектов

что я хочу?

- снизить размерность признакового описания объектов


какие я предъявляю пожелания?

- сохранение отношений близости
- сохранение порядка
- (?) визуализация структуры в данных
- (?) сохранение статистических свойств данных

Снижение размерности: метод главных компонент (PCA)

Идея:

- Предположим, что признаки в наборе данных скоррелированы;
- Перейдем в новые координаты, где признаки полностью раскоррелированы;
- Будем делать это «жадно»: выбирая новые признаки один за другим таким образом, чтобы суммарная объясненная дисперсия с каждой итерацией прирастала максимально.
- Для идеального восстановления исходных признаков необходима исходная размерность новых признаков;
- Для восстановления с потерями достаточно меньшего количества признаков; будем сохранять не менее 90% дисперсии.




Снижение размерности: метод главных компонент (PCA)

$$X \in \mathbb{R}^D$$

$$\text{cov}(X_i, X_j) = \mathbb{E} \left((X_i - \mu_i)(X_j - \mu_j) \right)$$

$$\text{cov}(X_i, X_j) = \mathbb{E}(X_i X_j) - \mu_i \mu_j$$



Снижение размерности: метод главных компонент (PCA)


$$X \in \mathbb{R}^D$$

$$\text{cov}(X_i, X_j) = \mathbb{E} \left((X_i - \mu_i)(X_j - \mu_j) \right)$$

$$\text{cov}(X_i, X_j) = \mathbb{E}(X_i X_j) - \mu_i \mu_j$$

$$\text{cov}(X_i, X_j) = \text{cov}(X_j, X_i)$$

$$\text{cov}(X_i, X_i) = \text{Var}(X_i)$$



Снижение размерности: метод главных компонент (PCA)

$$X \in \mathbb{R}^{D \times N}$$

$$\text{cov}(X_i, X_j) = \mathbb{E}((X_i - \mu_i)(X_j - \mu_j))$$


$$\text{cov}(X_i, X_j) = \mathbb{E}(X_i X_j) - \mu_i \mu_j$$

$$\text{cov}(X_i, X_j) = \text{cov}(X_j, X_i)$$

$$\text{cov}(X_i, X_i) = \text{Var}(X_i)$$

$$\Sigma = \mathbb{E}[(X - M)(X - M)^T]$$

$$M = \mathbb{E}(X)$$



Снижение размерности: метод главных компонент (PCA)

$$X \in \mathbb{R}^{D \times N}$$

$$\Sigma = \mathbb{E}[X^o X^{oT}]$$

$$\Sigma \in \mathbb{R}^{D \times D}$$


Σ – квадратная, симметричная, действительная
(=> эрмитова)

Тогда:

Σ имеет D собственных значений λ_d и собственных векторов ξ_d

$$\Sigma \xi_d = \lambda_d \xi_d$$

(!!!) максимальная дисперсия данных достигается вдоль собственного вектора ξ_d^* , соответствующего максимальному собственному значению λ_d^* .



Снижение размерности: метод главных компонент (PCA)

(!!!) максимальная дисперсия данных достигается вдоль собственного вектора ξ_d^* , соответствующего максимальному собственному значению λ_d^* .

1. Центрируем исходные признаки $\rightarrow X^o$;
2. Найдем Σ , найдем собственные значения λ_d и собственные векторы ξ_d матрицы Σ ;
3. Отранжируем их по величине собственных значений λ_d по убыванию;
4. Возьмем k максимальных собственных значений и соответствующих им собственных векторов;
5. умножим исходную матрицу признаков $X^o \in \mathbb{R}^{N \times D}$ на матрицу k собственных векторов ($V_{(k)} \in \mathbb{R}^{D \times k}$) – получим матрицу $Z \in \mathbb{R}^{N \times k}$ новых признаков-проекций на собственные векторы;

